

医学图像配准

- 图像配准

- 定义：将两个或多个图像进行几何对齐，使源图像（移动图像）上的每一个点在目标图像（固定图像）上都有唯一的点与其对应
- 目的：去除或者抑制待配准图像之间的几何不一致，寻找两个或多个图像之间的映射关系

- 传统方法

- 分类

- 基于灰度的方法：互信息法、序列相似度配准法、互相关法
- 基于特征方法
 - 经典方法：sift提取特征，结合随机抽样一直算法筛选特征，得到匹配点坐标，从而计算图像变换参数。
 - 核心步骤：特征提取、特征匹配、模型参数估计、图像变换和灰度插值。

- 特点：

- 使用范围窄
- 计算速度不够快，对于每一对对待配准的图像，传统的配准方法从零开始迭代优化代价函数，严重限制了配准速度，忽略了同一数据集图像间共享的固有配准模式

- 基于深度学习方法

由于选了TransMorph该篇论文，主要讨论无监督的、可变形的配准方法

- 选择无监督方法的原因

- 全监督配准

- 方式：以图像对间的真实变换(金标准)作为监督信息,采用真实 变换参数和估计变换参数间的误差损失监督网络训练。
- 问题：最大挑战是金标准 ϕ_{gt} 的获取成本高昂,且高度依赖专业知识,仅有极少数 研究使用由专家手动配准的训练数据。

- 双监督配准和弱监督配准

- 双监督：“双监督配准在使用参数误差损失基础上又额外 加入图像相似度损失,以降低对金标准的依赖。”
- 弱监督：“弱监督使用分割掩码、生物关键点等标签信息替代金标准。”
- 问题：这两种配准方法仍然需要大量的数据 标注,并未完全消除网络训练对监督信息的依赖。

- 无监督配准

- “无监督配准则不再需要任何标注数据,仅使 用图像相似度损失监督网络训练。 后续的文献梳理 也将按照监督信息递减的线索来组织”
- 难点：定义合适的网络损失函数——STN网络解决

- 空间变换网络 (spatial transformer network, STN)。STN 允许网络根据变形场(deformable fields, DFs) 实现对 I_m 的空间变换,是一个完全可微的模块,能被插入到现有的 卷积配准网络中。STN 模块使得在训练过程中计算图像相似度损失成为可能,推动了无监督配准研究的发展

- 无监督配准网络框架

- 输入: 图像对 I_m, I_f , I_f 是参考图像
- 结构组成;
 - 估计变形场网络 (CNN/FCN/Transformer) : 估计高维变形场 Φ^*
 - 空间变换网络 (STN) : 实现对 I_m 的扭曲变换得到 I_m^{warped}
- 优化目标: 计算 I_f 和 I_m^{warped} 间的图像相似度损失, 并最小化。

$$\Phi^* = \arg \min_{\Phi} L_{\text{sim}}(I_m^{\text{warped}}, I_f)$$

- 一些比较有代表性的方法和结论:

- 采用卷 积自编码器将输入的 I_m 和 I_f 编码为特征向量后计 算基于特征的相似度损失。结果表明, 基于特征的 相似度度量方法优于基于灰度的相似度度量方法。
- 经典无监督配准框架VoxelMorph: 通过级联 U-Net 和 STN 结构一步估计稠密的 变形场 Φ^* ,实现 3 维脑部 MRI 图像的可变形配准。网络借助 STN 模块在训练过程中计算图像相似度 损失,对 I_m^{warped} 和 I_f 间出现的外观差异进行惩罚
- 引入解剖分割标签, 分割图的引入为配准网络提供了更多 辅助信息,新增的标签 相似度约束能使网络收敛到 更优的可变形变换参数,有助于提高配准精度。

- 可改进的点:

- 相似度度量方式
- 跨膜态图像映射到同一域空间, 统一 I_m 和 I_f 的数据分布, 好的映射方法
- 加正则项进一步约束: 图像相似度损失、平滑度损失、对抗损失等。

- 评价指标

- Dice 相似系数(Dice similarity coefficient, DSC)
- 平均表面距离(average surface distance, ASD)